

Taller de Programación

TRABAJO PRÁCTICO N° 3

CLASIFICANDO DE POBRES CON LA EPH

Fecha de entrega: 15 de noviembre a las 13:00 hs.

Contenido: Comenzar con la aplicación de los métodos de clasificación vistos en clase para identificar pobres usando la EPH y validación cruzada.

Modalidad de entrega

- El informe debe subirse a la carpeta correspondiente en repositorio de GitHub del grupo en formato PDF con el nombre **Program_TP3_Grupo#.pdf** (donde # es el número de grupo), incluyendo gráficos e imágenes dentro del mismo archivo. El mismo debe tener link al repositorio del grupo en la primer pagina. La extensión máxima es de **8 páginas (sin apéndices)** y se espera una redacción clara y precisa.
- Se debe publicar el código con los comandos utilizados en el repositorio, indicando claramente a qué inciso corresponde cada uno. El nombre del archivo deberá ser **Program_TP3_Grupo#**.
 - Al finalizar el trabajo práctico deben hacer un último commit en su repositorio de GitHub llamado “*Entrega final del TP*”.
 - El Jupyter Notebook y el correspondiente al TP3 deben estar dentro de esa carpeta.
 - La última versión en el repositorio es la que será evaluada. Por lo que es importante que:
 - No suban el pdf en la sección de “**Actividades/Entregas**” del campus hasta no haber terminado y estar seguros de que han hecho el *commit* y *push* a la versión final que quieren entregar.
 - No hagan nuevos *push* despues de haber entregado su versión final. Esto generaría confusión acerca de que versión es la que quieren que se les corrija.
- **Cualquier detección de copia o plagio será sancionada.**

El objetivo de este trabajo práctico es intentar predecir si una persona es pobre o no utilizando distintas variables de características individuales que limpiaron y los distintos clasificadores vistos en clase. Recuerden que en los trabajos prácticos anteriores crearon dos bases de datos distintas: respondieron, que tiene datos de personas que sí respondieron su ingreso (ITF) y norespondieron, que tienen aquellas personas que no declaran su ingreso.

A. Enfoque de validación

Utilicen la base respondieron. Para cada año, dividan las observaciones en una base de prueba (test) y una de entrenamiento (train) utilizando el comando `train_test_split`. La base de entrenamiento debe comprender el 70% de los datos, y la semilla a utilizar (*random state instance*) debe ser 444. Establezca a pobre como su variable dependiente en la base de entrenamiento (vector y). El resto de las variables seleccionadas serán las variables independientes (matriz X). Recuerden agregar la columna de unos (1) para el intercepto. *Aclaración: no incluir la variable ingreso en X para predecir la pobreza porque cuando vayamos a la base de norespondieron no vamos a tener esa información.*

1. Cree una tabla de diferencia de medias entre la base de entrenamiento y la de testeo de las características seleccionadas en su matriz X. Para la matriz de las X seleccione variables que hayan limpiado en los TPs anteriores y justifique su inclusión para predecir la pobreza. Comente la tabla de la diferencia de medias de sus variables entre entrenamiento y testeo. ¿Hay diferencias significativas entre las medias del entrenamiento y testeo?
2. Separen la base respondieron en dos: respondieron_2005 y respondieron_2025. Idem con la base norespondieron.

B. Modelo de Regresión Logística

3. *Estimación y Efectos Marginales*: Estimen una **Regresión Logística** usando `X_train` de respondieron_2025. Exporten una tabla con: (i) los coeficientes estimados para cada variable, (ii) los errores estándar y (ii) los odd-ratios. Interpreten los resultados de la tabla. (*Hint*: en la clase 7 hay una ilustración de la tabla).
4. *Visualización*: Grafiquen la $\hat{P}(Y = 1|X)$ (en el eje vertical) y alguna característica **numérica** (en el eje horizontal). Comente dicho gráfico y la variable seleccionada para ilustrar la probabilidad de ser pobre según la característica seleccionada. (*Hint*: en la clase 7 hay una ilustración de este estilo).

C. Método de Vecinos Cercanos (KNN)

5. Estimación: Clasifiquen a las observaciones como “pobre”/“no pobre” en su región con Vecinos Cercanos (**KNN**) usando $K=\{1,5,10\}$ para su matriz X_{train} de respondieron_2025. Expliquen en no más de 2-3 oraciones cómo la elección de K se relaciona con el trade-off sesgo varianza.
6. Visualización: Grafiquen dos características numéricas de su matriz X_{train} y visualicen las clases predichas por KNN usando con $K=(1,10)$ con su frontera por clase “pobre”/“no pobre”.
7. K optimo por Cross-validation: Dividan la base X_{train} de respondieron_2025 en 5 partes (5-fold) para obtener el K óptimo por Cross-Validation con $K=(1,10)$. Llamenle a este modelo **KNN con K-CV**. Grafiquen el *accuracy* de cada modelo y comenten cual es el número óptimo de vecinos cercanos para identificar pobres.

D. Desempeño de modelos afuera de la muestra, métricas y políticas públicas

8. Comparen el desempeño de predicción de pobreza en la base de X_{test} en 2025 de los modelos Logit y KNN con K-CV. Muestren:
 - i. la matriz de confusión (con umbral $p > 0.5$) para logit,
 - ii. la curva ROC de ambos modelos en un solo gráfico,
 - iii. un tabla con dos métricas de clasificación vista en clase de ambos modelos, e interprete los resultados.
9. Suponga que el Ministerio de Capital Humano esta interesado en identificar a grupos vulnerables para dirigir los recursos de un programa de alimentos. Discutan cuál modelo de clasificación es “mejor” para predecir pobres y asignar dichos recursos de alimentos escasos. (*Hint:* recuerden que en la clase de clasificación discutimos el trade-off de minimizar error tipo I o II)
10. Con el método que seleccionaron, predigan qué personas son pobres dentro de la base norespondieron para 2025. ¿Qué proporción de las personas que no respondieron pudieron identificar como pobres?